Detecção e classificação de objetos com YOLOv8

Relatório técnico do projeto | Visão computacional e aprendizado supervisionado

Visão geral e objetivo

O projeto treina e avalia um detector de objetos baseado em YOLOv8 para reconhecer três classes em imagens e vídeo: bolsas, óculos e relógios. A avaliação observa precisão, recall, mAP, evolução das perdas durante o treinamento e exemplos de inferência. O foco é estudar a identificação de objetos sob variações de iluminação, ângulo e oclusão.

Tecnologias e ambiente

Python 3.12; Ultralytics YOLOv8 v8.4.56; PyTorch, OpenCV, Pillow (PIL), Matplotlib e Pandas. Treinamento relatado em Google Colab com GPU Tesla T4. Modelo inicial: yolov8s.pt.

Dados e metodologia

A base descrita no relatório contém aproximadamente 500 imagens obtidas do Pexels, distribuídas em 165 imagens de relógios, 165 de óculos e 170 de bolsas. Os exemplos contemplam diferentes objetos, contextos, ângulos e obstruções. As imagens foram organizadas em train, valid e test, com anotações em arquivos .txt no formato YOLO.

O treinamento supervisionado utilizou imagens de 640 × 640 pixels durante 50 épocas. Foram monitoradas métricas e perdas, seguidas de validação e geração de curvas de precisão-recall e matrizes de confusão. O relatório original também registra inferência em imagens e vídeo.

Resultados de validação apresentados no relatório original

Classe	Precisão	Recall	mAP@0.5	mAP@0.5:0.95
Bolsa	0,783	0,667	0,753	0,491
Óculos	0,763	0,848	0,862	0,631
Relógio	0,871	0,794	0,840	0,483
Geral	0,806	0,770	0,818	0,535

Os valores acima correspondem à validação descrita como ONNX, etapa 8, no documento de origem. Eles são resultados reportados, e não uma reexecução independente dos experimentos.

Interpretação dos resultados

O modelo alcançou mAP@0.5 geral de 0,818 e mAP@0.5:0.95 de 0,535. Relógios apresentaram a maior precisão (0,871), enquanto óculos obtiveram o maior recall (0,848). A classe bolsa foi a de menor recall (0,667), com maior dificuldade de identificação em alguns cenários. Segundo o relatório, as perdas diminuíram progressivamente e as métricas ficaram mais estáveis por volta das épocas 40 a 45.

Limitações identificadas

O conjunto de dados relativamente pequeno limita a diversidade de exemplos. Houve confusões entre algumas classes e dificuldades com objetos parcialmente ocultos, muito pequenos ou capturados em condições complexas de iluminação e ângulo. As métricas de validação não garantem desempenho equivalente em situações reais ou bases externas.

Possíveis evoluções

Ampliar a diversidade e a quantidade de imagens por classe; testar aumento de dados (data augmentation) para aprimorar robustez; comparar com variantes maiores, como YOLOv8m e YOLOv8l, especialmente nos casos de objetos pequenos ou parcialmente ocultos. Essas iniciativas são propostas futuras, não etapas já executadas.

Nota sobre reprodução

Para reproduzir os resultados, é necessário dispor do dataset e das anotações apropriadas, além do notebook e das dependências compatíveis. Avaliar licenças e permissões de redistribuição das imagens antes de publicar os dados.